끊임없이 도전하는
유지상 입니다.

#Deep Learning #Computer Vision
#Visual SLAM #Robotics #Multimodal Learning
#Object Detection #Reinforcement Learning

Contact

📱010-3321-1528 | 📧jisang1528@g.skku.edu

끊임없이 성장하는 연구자 유지상입니다

저는 딥러닝 기반 컴퓨터 비전 기술을 활용하여 3D Reconstruction, Visual SLAM, Multimodal learning, VLM 등 다양한 분야에 응용할 수 있는 연구개발을 추구합니다.
새로운 도전을 두려워하지 않고, 항상 열정적으로 배우고 탐구하며 성장해 나가고 있습니다.
앞으로도 끊임없는 도전을 통해 한계를 넘어서는 기술을 만들어가고자 합니다.

🎓 Education

2024.03 ~ 2026.02	**성균관대학교**	지능형로봇학과	CGPA: **4.4** / 4.5
2022.03 ~ 2024.02	**아주대학교**	미래자동차연계전공	CGPA: **4.5** / 4.5
2018.03 ~ 2024.02	**아주대학교**	전자공학과	CGPA: **4.14** / 4.5

🏢 Professional Experience

2026.01 ~ 2026.06 **카카오모빌리티** DeepAI팀 연구 인턴십

📄 Publications

2025 SelfSplat: Pose-Free and 3D Prior-Free Generalizable 3D Gaussian Splatting (CVPR 2025) – **공동 1저자**

2025 OpenMonoGS-SLAM: Monocular Gaussian Splatting SLAM with Open-set Semantics (SCIE 저널 심사중) – **1저자**

📁 Extracurricular Activities

2026 AI Agent (RAG, LangChain) 교육 수료 및 QA봇 프로젝트 수행

2025 연구실 서버관리 업무 수행

2024 이상탐지(Anomaly detection) 프로젝트

2023 2023 대학생 창작 자율주행 경진대회

2023 번호판 비식별화 프로젝트

2022 네트로닉스 (소학회) 교육 부장

2022 인공지능 스터디

🏆 Award

2024.02 H-mobility Class (자율주행과정) **우수학습자 선발**

2023.12 아주대학교 전자공학과 산학박람회 **장려상**

2023.12 2023 경기도자율주행센터 데이터 활용 경진대회 **은상**

2022.11 2022 AI 융합 아이디어 경진대회 **1등상**

2022.08 국민대 스케일카 기반 자율주행 경진대회 **우수상**

🎖 Scholarship

2024.03 혁신융합단 성과우수장학

2023.09 율곡장학

2023.03 다산장학

2023.03 혁신융합단 성과우수장학

2018.09 김용득장학

2018.09 학장추천장학(정통대)

👨‍💻 Programming Skills

- Python (PyTorch, TensorFlow)
- C/C++
- MATLAB
- ROS (Robot Operating System)
- Linux (Ubuntu)

🔎 SelfSplat: Pose-Free and 3D Prior-Free Generalizable 3D Gaussian Splatting (CVPR 2025)

Gyeongjin Kang*, **Jisang Yoo***, Jihyeon Park, Seungtae Nam, Sangpil Kim, Hyeonsoo Im, Sangheon Shin, Eunbyung Park

Background [Project Page]

- Self-supervised Depth Estimation

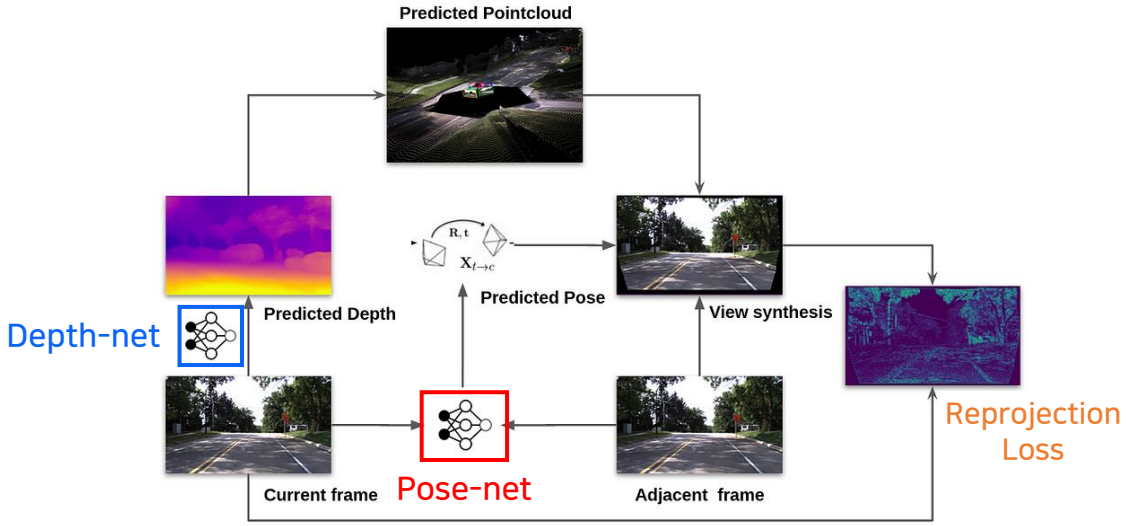

[자기지도학습 기반 깊이 예측 파이프라인]

- Self-supervised Depth Estimation은 **Depth-net**을 통해 얻은 Depth 정보와 **Pose-net**을 통해 얻은 Camera Pose 정보를 활용하여 **자기지도학습 방식**으로 **3D 기하 정보**를 학습하는 방법입니다.

✓ **Reprojection Loss**: 예측한 **depth**와 **pose**를 이용해 다른 시점의 이미지를 다시 만들어 보고, 이 이미지가 실제 원본과 비슷해지도록 학습하는 Loss입니다.

- 3D Gaussian Splatting (3DGS)

[3D Gaussians scene]

✓ 3D Gaussian Splatting은 **3D Gaussian**으로 Scene을 표현하고, Splatting을 통해 원하는 시점의 이미지를 렌더링하는 3D 표현 방법입니다.

✓ **고품질 이미지를 빠르게 렌더링**할 수 있다는 장점이 있지만, 각 Scene마다 **별도의 최적화 학습이 필요**하다는 한계가 있습니다.

- Generalizable 3D Gaussian Splatting

✓ Generalizable 3DGS는 기존 3DGS의 단점을 극복하기 위해, 대규모 데이터셋으로 학습된 **Feed-Forward Network**를 통해, 새로운 Scene을 **추가 학습 없이 빠르게 복원**하는 방법입니다.

🔎 SelfSplat: Pose-Free and 3D Prior-Free Generalizable 3D Gaussian Splatting (CVPR 2025)

Gyeongjin Kang*, **Jisang Yoo***, Jihyeon Park, Seungtae Nam, Sangpil Kim, Hyeonsoo Im, Sangheon Shin, Eunbyung Park

Introduction [Project Page]

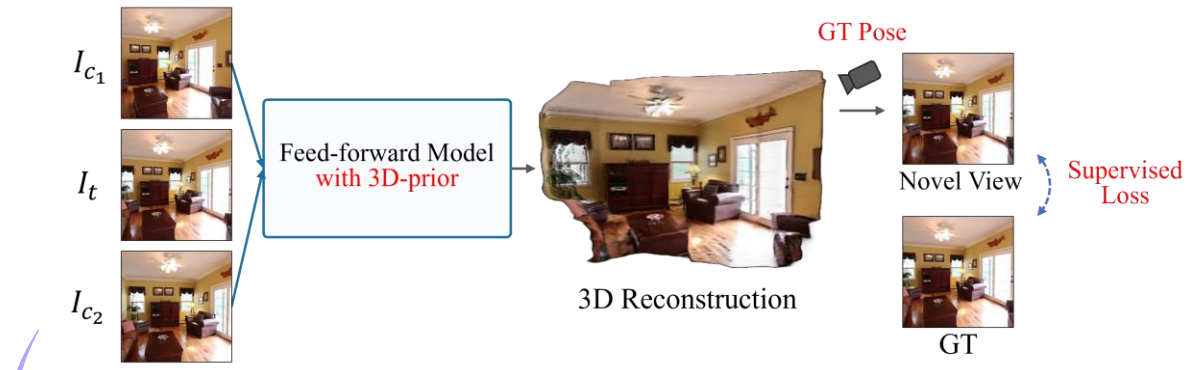

3D-prior와 GT Pose가 필요한 기존 방식

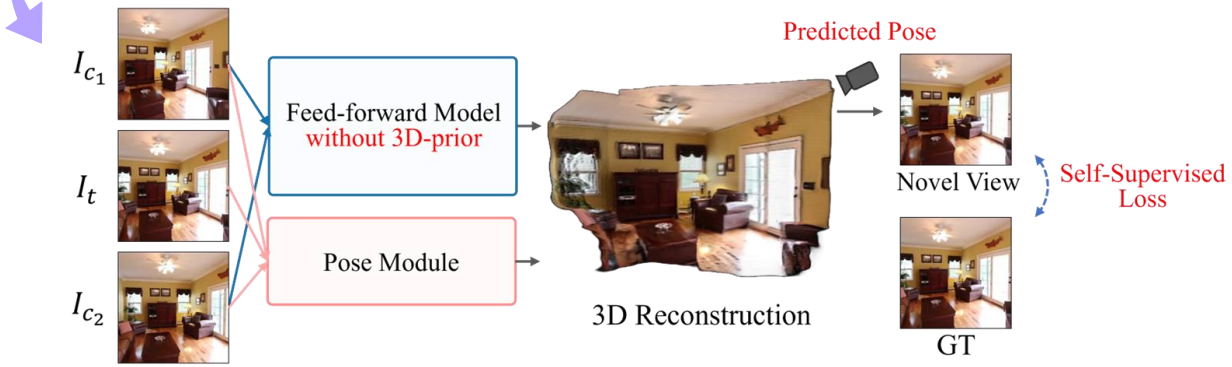

제안 방식

- Motivation

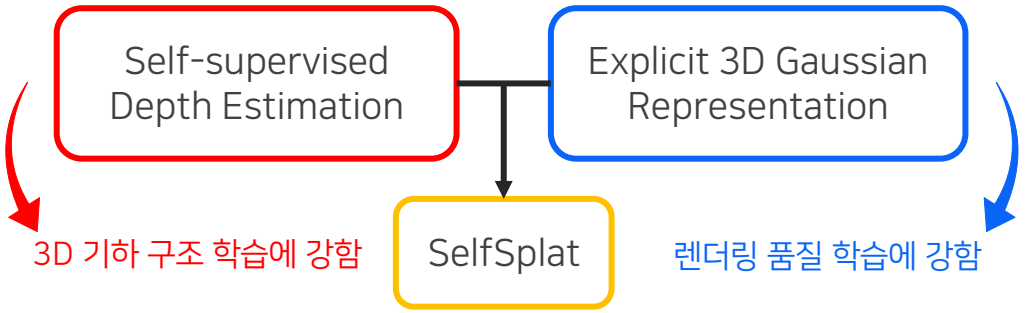

두 방식의 장점을 결합하여 시너지 효과 도출

- 기존 방식은 **Generalizable Feed-forward model**을 학습하기 위해 다음 정보에 의존한다는 단점이 존재합니다.
  - ✓ **3D-prior**가 학습된 pretrain model (DUSt3R, MASt3R 등)
  - ✓ **GT Camera Pose**
- 따라서 본 논문에서는 3D-prior와 GT Camera Pose 정보를 필요로 하지 않고, 완전한 Self-supervised 방식으로 Generalizable Feed-forward model을 학습하는 방법을 제안했습니다.

SelfSplat: Pose-Free and 3D Prior-Free Generalizable 3D Gaussian Splatting (CVPR 2025)

Gyeongjin Kang*, **Jisang Yoo***, Jihyeon Park, Seungtae Nam, Sangpil Kim, Hyeonsoo Im, Sangheon Shin, Eunbyung Park

Method [Project Page]

- Pose-aware Depth Refinement Module

✓ 예측한 Depth와 Plücker ray embedding을 함께 입력으로 받는 Depth Refine Net을 통해 **불완전한 Depth를 조정**할 수 있도록 합니다.

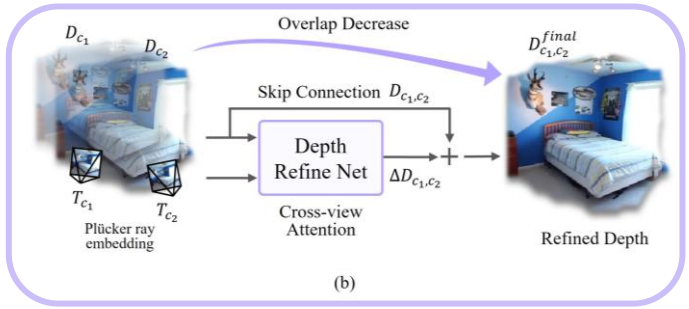

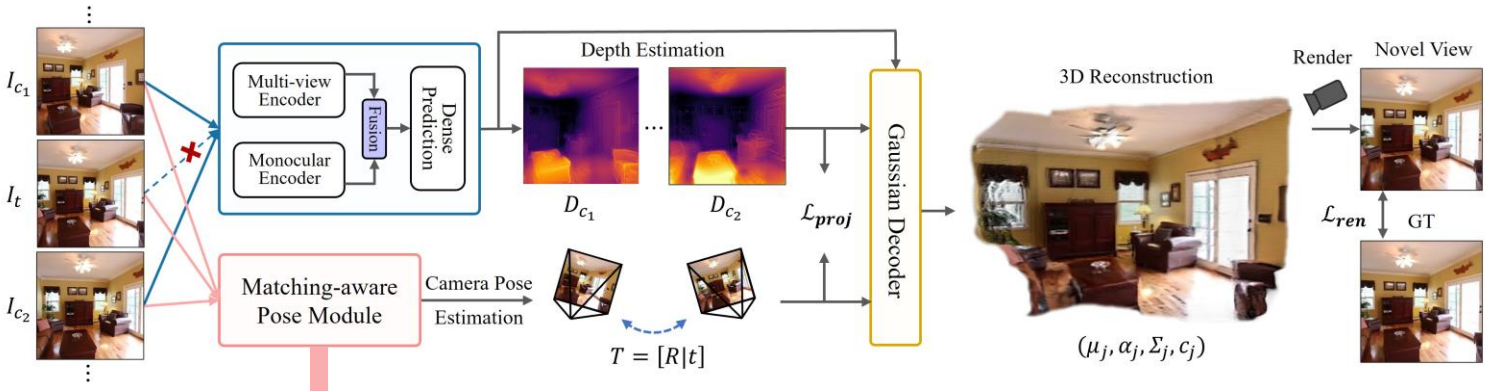

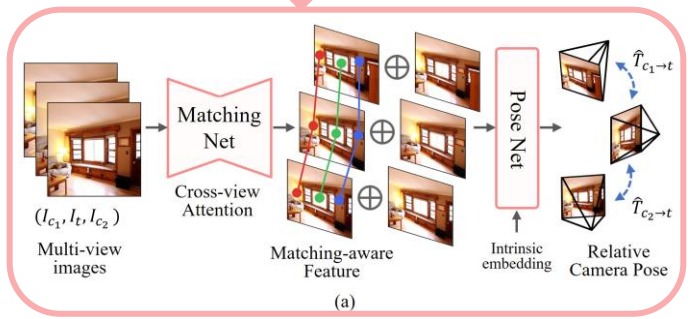

- Matching-aware Pose Estimation Module

✓ Cross-view Attention 기반 Matching Net을 통해 얻은 **매칭 정보를 활용**하여, Pose Net이 각 이미지 간의 상대적인 Camera Pose를 추정할 수 있도록 합니다.

- Loss Function

✓ Reprojection Loss ($\mathcal{L}_{proj}$): ⟶ 3D 기하 구조 학습

추정된 Camera pose를 기반으로, Reference view에서 Target view로 픽셀값을 재투영하여 Loss 계산합니다.

✓ Rendering Loss ($\mathcal{L}_{ren}$): ⟶ 렌더링 품질 학습

3D Gaussian을 렌더링하여 생성한 이미지와 실제 이미지 간의 차이를 계산합니다.

- 설계 기여

✓ Croco 기반 **Monocular Encoder**와 UniMatch 기반 **Multi-view Encoder를 설계**하고, DPT head를 통해 통합하는 **아키텍처를 설계**했습니다.

✓ Self-supervised learning을 위해 학습 이미지 간의 **Reprojection Loss를 직접 구현**하였습니다.

✓ **Curriculum Learning**을 통해 학습이 안정적으로 진행되도록 하였습니다.

🔎 SelfSplat: Pose-Free and 3D Prior-Free Generalizable 3D Gaussian Splatting (CVPR 2025)

Gyeongjin Kang*, **Jisang Yoo***, Jihyeon Park, Seungtae Nam, Sangpil Kim, Hyeonsoo Im, Sangheon Shin, Eunbyung Park

Experiments [Project Page]

- Novel-view Synthesis (렌더링 품질)

Method	RE10k PSNR ↑	RE10k SSIM ↑	RE10k LPIPS ↓	ACID PSNR ↑	ACID SSIM ↑	ACID LPIPS ↓
VAE	20.65	0.643	0.325	24.02	0.666	0.287
DBARF	12.57	0.494	0.474	15.48	0.572	0.397
FlowCAM	22.29	0.711	0.313	25.59	0.721	0.294
CoPoNeRF	21.03	0.693	0.256	23.30	0.668	0.278
Ours	**24.22**	**0.813**	**0.188**	**26.71**	**0.801**	**0.196**

- Pose Estimation (카메라 포즈 예측 성능)

Method	RE10K Rotation Avg.° ↓	RE10K Rotation Med.° ↓	RE10K Translation Avg.° ↓	RE10K Translation Med.° ↓	ACID Rotation Avg.° ↓	ACID Rotation Med.° ↓	ACID Translation Avg.° ↓	ACID Translation Med.° ↓
VAE	3.859	2.818	115.746	113.598	1.631	0.461	86.180	79.987
DBARF	2.471	1.471	36.069	24.308	1.975	0.860	49.906	95.399
FlowCAM	1.438	1.160	22.524	15.917	3.846	2.819	92.786	82.976
CoPoNeRF	0.839	0.587	9.175	5.538	1.058	0.354	19.888	9.757
Ours	**0.750**	**0.362**	**9.095**	**4.438**	**0.981**	**0.199**	**16.329**	**4.535**

- Cross-dataset Generalization (일반화 성능)

Method	RE10k → ACID PSNR ↑	RE10k → ACID SSIM ↑	RE10k → ACID LPIPS ↓	ACID → RE10k PSNR ↑	ACID → RE10k SSIM ↑	ACID → RE10k LPIPS ↓
FlowCAM [42]	25.31	0.715	0.297	21.13	0.667	0.329
CoPoNeRF [21]	23.56	0.683	0.287	18.89	0.607	0.364
Ours	**26.60**	**0.793**	**0.206**	**21.65**	**0.728**	**0.242**

- Ablation studies

Method	PSNR ↑	SSIM ↑	LPIPS ↓	Rot. Avg.° ↓	Trans. Avg.° ↓
Ours	**22.65**	**0.764**	**0.222**	**1.036**	**13.705**
No Matching Network	22.21	0.735	0.241	1.308	15.171
No Depth Refine	22.05	0.744	0.224	1.064	14.8
No Reprojection Loss	21.12	0.672	0.293	2.236	28.584
No Rendering Loss	-	-	-	8.581	64.436

- Qualitative Evaluations

- **성장 역량**
  - ✓ SelfSplat 연구를 통해 **자기지도학습 기반 3D Vision 연구 역량**과 **AI 아키텍쳐 설계 역량**을 길렀습니다.
  - ✓ 또한 실험 설계와 하이퍼파라미터 조정을 통해 **성능을 고도화하는 역량**도 길렀습니다.

🔎 OpenMonoGS-SLAM: Monocular Gaussian Splatting SLAM with Open-set Semantics

Jisang Yoo, Gyeongjin Kang, Hyun-kyu Ko, Hyeonwoo Yu, Eunbyung Park

Background [Project Page]

- Visual SLAM

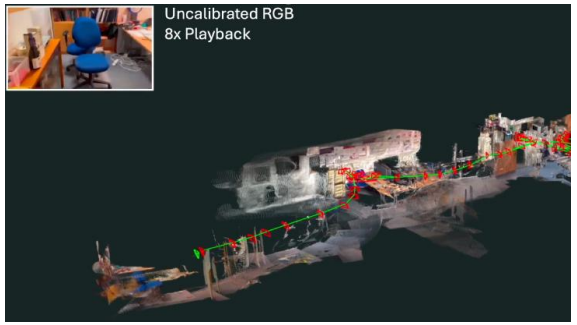

[Visual SLAM 예시]

- Visual SLAM이란?
  - ✓ 카메라로 입력되는 영상을 바탕으로, **주변 환경의 지도**를 만들면서 동시에 **카메라 자신의 위치**를 추정하는 기술입니다.

- SLAM 프레임워크

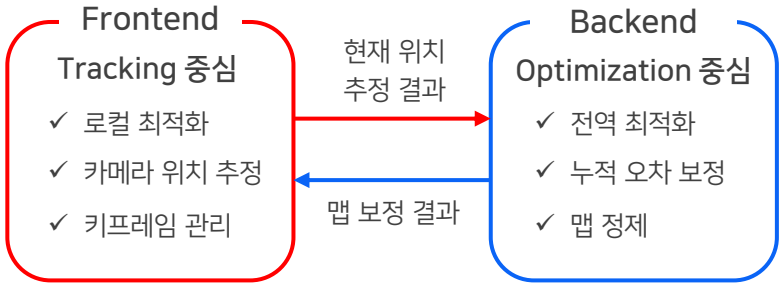

✓ Frontend: 현재 맵 정보를 활용해 카메라의 위치를 실시간으로 추정하고, 키프레임을 선정합니다.

✓ Backend: 키프레임 카메라 정보를 바탕으로 전체 맵을 최적화하여 누적 오차를 보정합니다.

- Semantic SLAM

[RGB 맵]

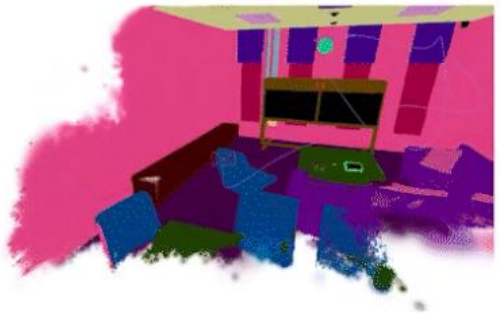

[Semantic 맵]

- Semantic SLAM이란?
  - ✓ 카메라 정보를 바탕으로 RGB 기반의 맵을 생성하는 것을 넘어, **객체의 semantic 정보**를 함께 추정하여 **주변 공간의 의미**까지 파악하는 기술입니다.

- Semantic SLAM 활용 가능성
  - ✓ Semantic SLAM은 **Embodied AI**의 핵심 기술로, 로봇 내비게이션, AR/VR, 디지털 트윈 등 다양한 응용으로 확장될 수 있습니다.
    - ❖ **Embodied AI**는 Agent가 **실제 물리적 환경**과 상호작용하며 지각과 행동을 통합적으로 수행하는 **AI 기술**입니다.

🔎 OpenMonoGS-SLAM: Monocular Gaussian Splatting SLAM with Open-set Semantics

Jisang Yoo, Gyeongjin Kang, Hyun-kyu Ko, Hyeonwoo Yu, Eunbyung Park

Introduction [Project Page]

- Closed-set Semantic Segmentation

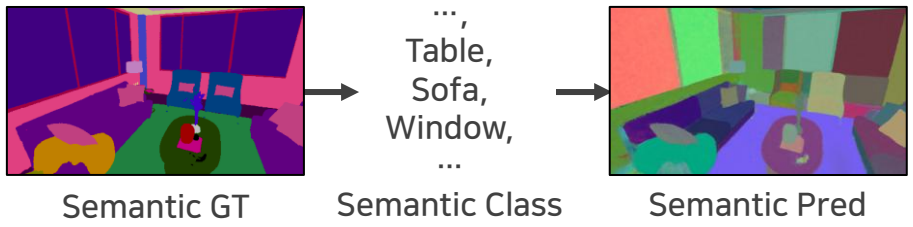

✓ 미리 정의된 고정된 클래스 집합으로 학습 및 평가됩니다.

✓ 따라서 해당 클래스 이외의 객체는 인식하거나 처리할 수 없습니다.

- Open-set Semantic Segmentation

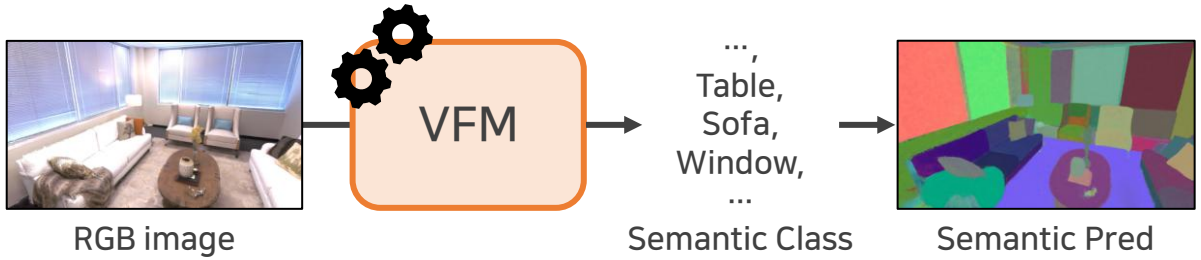

✓ VFM을 활용하여 사전에 정의된 클래스 뿐만 아니라 **새로운 클래스**도 인식할 수 있습니다.

✓ 따라서 추론 시에 **새로운 객체**를 다룰 수 있습니다.

- VFM (Visual Foundation Model)
  - 대규모 이미지 데이터셋을 기반으로 사전 훈련된 모델로, 뛰어난 **일반화** (generalization) 및 **전이성**(transferability)을 보이는 것이 특징입니다.
  - 본 논문에서는 다음과 같은 VFM을 사용했습니다.

✓ MASt3R: 시각적 기하 구조(visual geometry)를 담당합니다.

✓ SAM (Segment Anything Model): 2D segmentation mask를 생성하는 역할을 합니다.

✓ CLIP: SAM에 의해 분할된 각 영역에 언어적 사전 정보(language prior)를 부여함으로써, Open-vocabulary 의미 이해를 가능하게 합니다.

- Contribution
  - 본 연구는 기존의 Closed-set Semantic SLAM을 넘어, VFM을 활용하여 어떠한 객체든 인식할 수 있는 Open-set Semantic SLAM을 제안합니다.
  - 깊이 센서(RGB-D)에 의존했던 기존 방식과 달리, 오직 **단일 RGB 카메라 (Monocular)** 입력만으로 고품질의 3D 재구성 및 Semantic Mapping을 동시에 달성합니다.
  - Multi-scale **표현**을 통해 다양한 크기의 객체의 특성을 학습합니다.
  - 실시간성과 메모리 효율이 중요한 SLAM의 특성을 고려하여, **메모리 어텐션 메커니즘**을 도입하여, 3D map의 메모리 효율성과 Semantic 표현력을 모두 극대화하는 융합 전략을 제안합니다.

OpenMonoGS-SLAM: Monocular Gaussian Splatting SLAM with Open-set Semantics

Jisang Yoo, Gyeongjin Kang, Hyun-kyu Ko, Hyeonwoo Yu, Eunbyung Park

Method [Project Page]

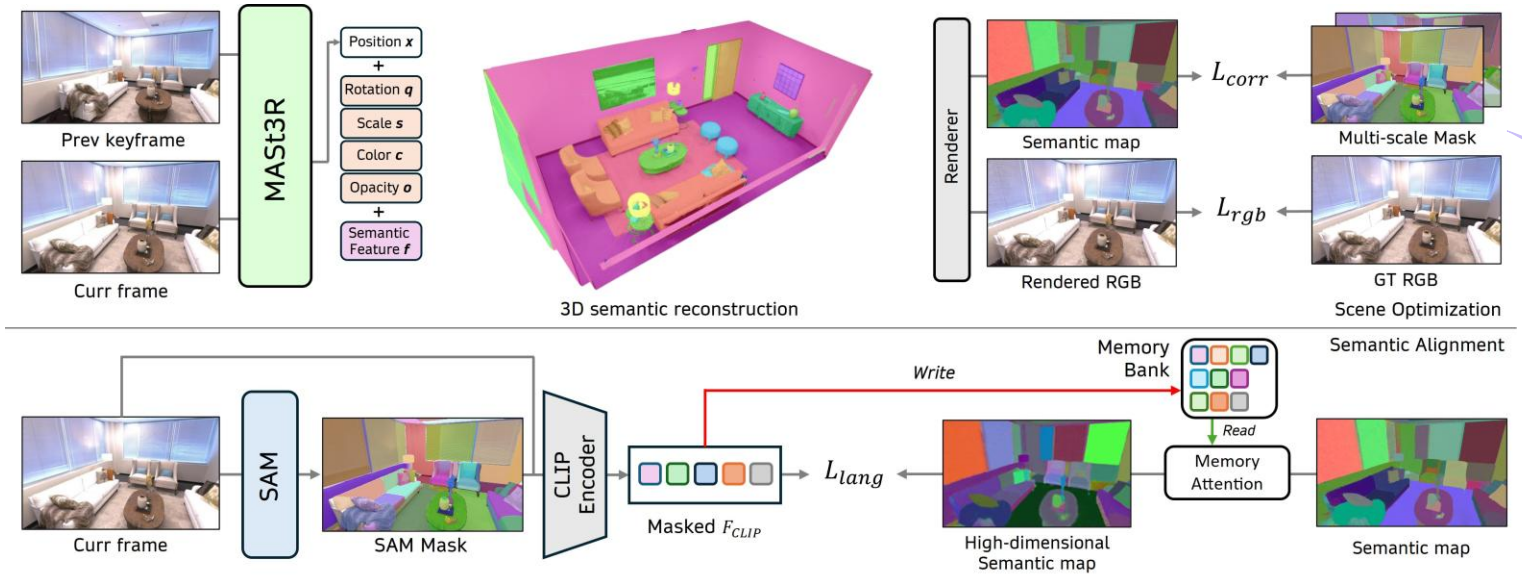

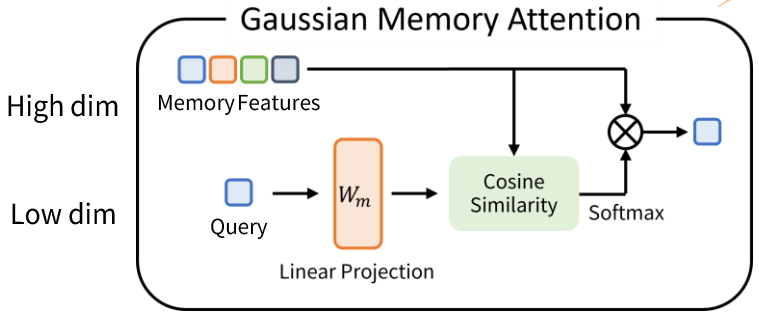

- **Language-embedded Semantic Memory Bank**
  - ✓ 고차원 CLIP feature의 효율적 관리를 위해, 대표 feature만 **Memory Bank**에 저장하고, **어텐션 메커니즘**을 통해 필요한 정보를 읽어옵니다.

- **3DGS-based Monocular SLAM**
  - ✓ MASt3R를 통해 3D point map을 생성하고, 이를 **3D gaussian map 초기화** 및 안정적인 **Camera Tracking**에 사용합니다.
  - ✓ 3D Gaussian의 기본 속성 외 학습 가능한 semantic feature를 추가하여 **기하정보**와 **의미 정보**를 동시에 표현합니다.

- **Multi-Scale Semantic Learning**
  - ✓ 3D 공간으로 투영된 2D 객체 마스크의 크기 정보를 활용하여, semantic feature가 객체의 **다중 스케일(multi-scale) 특성**을 내재적으로 학습하도록 유도합니다.

- **Self-Supervised Learning Objectives**
  - ✓ $\mathcal{L}_{rgb}$: 사실적인 렌더링을 위한 **RGB Loss**
  - ✓ $\mathcal{L}_{corr}$: 여러 시점 간 Semantic 일관성을 위한 **Contrastive Loss**
  - ✓ $\mathcal{L}_{lang}$: CLIP feature의 언어적 의미를 학습하는 **Regression Loss**

🔎 OpenMonoGS-SLAM: Monocular Gaussian Splatting SLAM with Open-set Semantics

Jisang Yoo, Gyeongjin Kang, Hyun-kyu Ko, Hyeonwoo Yu, Eunbyung Park

Experiments [Project Page]

- Novel-view Synthesis (렌더링 품질)

Methods	Input	Metrics	Avg.	room0	room1	room2	office0	office1	office2	office3	office4
Visual SLAM											
MonoGS (Matsuki et al. 2024)	RGB	PSNR ↑	27.77	26.23	25.28	27.87	31.28	33.61	23.78	27.97	26.15
		SSIM ↑	0.858	0.821	0.776	0.869	0.886	0.916	0.830	0.891	0.878
		LPIPS ↓	0.203	0.179	0.304	0.184	0.181	0.142	0.262	0.136	0.237
Photo-SLAM (Huang et al. 2024)	RGB	PSNR ↑	30.37	29.73	26.65	31.97	35.27	28.74	30.72	29.25	30.62
		SSIM ↑	0.904	0.874	0.828	0.930	0.941	0.878	0.937	0.912	0.931
		LPIPS ↓	0.161	0.156	0.246	0.115	0.125	0.227	0.143	0.139	0.138
SEGS-SLAM (Wen et al. 2025)	RGB	PSNR ↑	33.54	31.25	27.27	35.09	**38.56**	**38.64**	**34.42**	**33.90**	29.35
		SSIM ↑	0.927	0.901	0.826	0.953	0.969	0.957	0.955	0.952	0.908
		LPIPS ↓	0.104	0.092	0.203	**0.056**	**0.064**	0.108	**0.082**	0.074	0.153
Ours (SAM1.0)	RGB	PSNR ↑	**34.47**	**33.53**	**30.64**	**35.16**	38.41	38.59	32.10	33.49	**33.86**
		SSIM ↑	**0.957**	**0.953**	**0.914**	**0.967**	**0.969**	**0.971**	**0.959**	**0.959**	**0.963**
		LPIPS ↓	**0.086**	**0.066**	**0.153**	0.075	0.065	**0.084**	0.085	**0.067**	**0.093**
Semantic SLAM											
DNS-SLAM (Li et al. 2024b)	RGB-D	PSNR ↑	22.89	22.45	24.61	25.27	24.09	25.28	21.39	21.87	18.20
		SSIM ↑	0.851	0.844	0.882	0.900	0.891	0.809	0.880	0.870	0.832
		LPIPS ↓	0.231	0.231	0.230	0.231	0.195	0.259	0.251	0.256	0.283
SGS-SLAM (Li et al. 2024c)	RGB-D	PSNR ↑	32.11	29.83	**31.60**	32.68	36.75	37.28	29.72	28.63	30.36
		SSIM ↑	0.922	0.891	0.915	0.941	0.959	0.949	0.916	0.897	0.907
		LPIPS ↓	0.343	0.153	0.168	0.153	0.136	0.185	0.176	0.186	0.213
Hier-SLAM (Li et al. 2024a)	RGB-D	PSNR ↑	33.57	30.16	31.15	33.46	37.36	39.12	31.27	30.83	33.19
		SSIM ↑	0.933	0.896	0.902	0.947	0.961	0.965	0.932	0.925	0.936
		LPIPS ↓	**0.061**	0.085	**0.077**	**0.048**	**0.041**	**0.034**	**0.066**	**0.060**	**0.079**
Ours (GT)	RGB	PSNR ↑	**35.12**	**33.29**	31.20	**36.27**	**38.68**	**39.98**	**32.80**	**34.42**	**34.33**
		SSIM ↑	**0.960**	**0.952**	**0.918**	**0.972**	**0.970**	**0.976**	**0.963**	**0.966**	**0.966**
		LPIPS ↓	0.080	**0.067**	0.151	0.066	0.064	0.073	0.081	**0.058**	0.084

- Open-vocabulary segmentation (Text-prompt 기반 평가)

Methods	Avg.	R0	R1	R2	Of0	Of1	Of2	Of3	Of4
Feature 3DGS	0.571	0.506	0.569	0.527	0.633	0.598	0.613	0.529	0.593
Gaussian Grouping	0.690	0.613	0.631	0.732	0.744	0.683	0.763	0.664	0.686
Ours (SAM1.0)	**0.845**	**0.832**	**0.761**	**0.873**	**0.837**	**0.882**	**0.851**	**0.847**	**0.873**

- Qualitative Evaluations

[Open-vocabulary segmentation]

[Prompt segmentation]

- Closed-set segmentation (Semantic GT 기반 평가)

Methods	Avg.	R0	R1	R2	Of0	Of1	Of2	Of3	Of4
DNS-SLAM	0.742	0.818	0.831	0.748	0.671	0.798	0.759	0.721	0.589
SGS-SLAM	0.866	0.862	**0.887**	0.865	0.886	**0.927**	0.854	0.782	0.866
Hier-SLAM	0.804	0.869	0.767	0.844	0.817	0.807	0.830	0.740	0.793
Ours(Prior)	**0.896**	**0.886**	0.881	**0.900**	**0.904**	0.915	**0.909**	**0.875**	**0.901**

- Ablation Studies

Setting	mIoU↑	FWIoU↑	Acc↑	PSNR↑
w/o contrastive loss	0.477	0.628	0.697	34.02
w/o regression loss	0.616	0.660	0.705	34.30
w/o memory	0.520	0.615	0.656	34.38
Ours (SAM1.0)	**0.645**	**0.685**	**0.730**	**34.47**

- **성장 역량**

✓ OpenMonoGS-SLAM 연구를 통해 **멀티모달 Spatial AI 설계 역량**과, 온디바이스 적용 가능성을 고려한 **효율적인 시스템 설계 역량**을 길렀습니다.

끝없는 도전을 통해 어제보다 오늘 더 성장하는 연구자가 되겠습니다.

감사합니다.

(인턴십과 프로젝트에 대한 세부사항은 다음 부록을 참고해주시면 감사드리겠습니다.)

Contact

010-3321-1528 jisang1528@g.skku.edu

카카오 모빌리티 [DeepAI팀 연구 인턴십]

번호판 및 얼굴 비식별화 모델 개발

Overview

- 업무 개요
  - ✓ **개인정보보호법**에 따라 사내에서는 번호판과 얼굴 등의 개인정보를 포함한 데이터를 사용할 수 없으므로 비식별화가 필요합니다.
  - ✓ 2026년 1월부터 2월까지 번호판 비식별화 모델을 개발했고, **짧은 기간** 안에 **우수한 성능**을 달성하여 성공적으로 업무를 완료했습니다.
- 기여 사항
  - ✓ **데이터 정제, 학습, 평가, 자동라벨링(active learning)** 파이프라인을 통합 구축하여 효율적으로 모델을 개발했습니다.
  - ✓ 요구사항에 맞춰 **다양한 이미지**(평면/파노라마/회전 등)에서 안정적으로 동작하는 파이프라인을 구축했습니다.
  - ✓ **기존 Yolo 기반 사내 모델보다 mAP 기준 96.43%**의 성능 향상을 달성하며 성공적으로 **모델을 사내에 배포하였습니다.**

[번호판 비식별화 예시]

Details

- 데이터 정제의 필요성
  - CVAT 어노테이션 툴을 통한 데이터 정제

[부정확한 라벨 샘플 예시]

- ✓ 기존 학습 데이터에는 부정확한 라벨들이 다수 존재했습니다.
- ✓ **CVAT 어노테이션 툴**을 통해 부정확한 샘플들을 다시 라벨링하였습니다.

- 데이터 정제 파이프라인

1. SAM3를 통한 IoU 기반 필터링

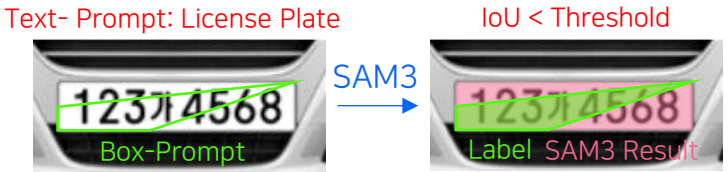

[SAM3 기반 필터링 예시]

- ✓ 기존 라벨을 box-prompt와 text-prompt로 사용하여 SAM3에 입력한 후, 결과 segment와 GT 라벨의 **IoU가 낮은 것**부터 정렬하여 필터링했습니다.
- ✓ IoU가 낮은 샘플부터 **다시 라벨링을 수행했습니다.**

2. Rectangularity & Polygon Approximation 기반 필터링

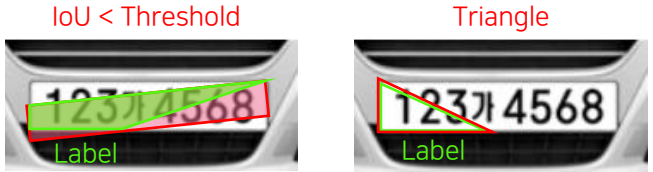

[Rectangularity ↓] [사각형 X]

- ✓ **Rectangularity 필터링**: 실제 라벨과 라벨이 만드는 직사각형 간의 IoU가 임계값보다 낮으면 필터링했습니다.
- ✓ **Polygon Approximation 필터링**: 다각형 근사를 통해 라벨이 사각형이 아니면 필터링했습니다.
- ✓ 위의 과정에서 필터링된 샘플들만 **다시 라벨링을 수행했습니다.**

카카오 모빌리티 [DeepAI팀 연구 인턴십]

번호판 및 얼굴 비식별화 모델 개발

Details

- **데이터셋 구성**

✓ 효율적인 데이터셋 구성을 위해 샘플링을 수행했습니다.

✓ FAISS k-means clustering

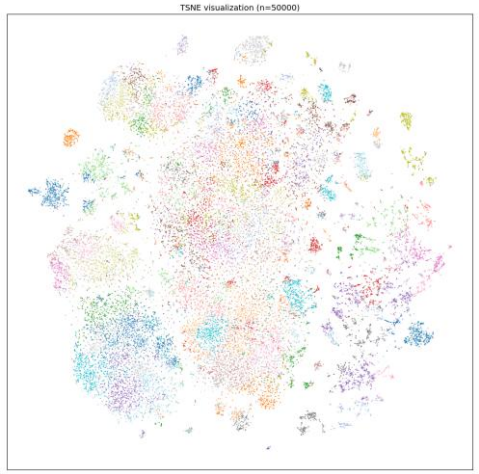

[Clustering 결과]

[Cluster 1]

[Cluster 2]

[Cluster 3]

[Cluster 4]

✓ Clustering을 통해 얻은 각각의 Cluster에서 일부 데이터를 샘플링하여 **데이터 분포를 다양하고 균일하게 구성하였습니다.**

- **모델 학습**

✓ 강력한 일반화 성능을 위해 트랜스포머 기반 객체인식 모델인 RF-DETR을 활용했습니다.

✓ 회전 객체 인식을 위해 다음과 같이 모델을 수정했습니다.

1. **Data Loader**: 회전 객체 라벨(OBB) 입력을 지원하도록 수정 및 cache 기반으로 효율적으로 구현
2. **Angle Head**: 회전각 예측을 위한 추가 예측 Head 설계
3. **Angle Loss**: 예측 회전각과 정답 회전각의 차이를 최소화하는 각도 손실 함수 도입
4. **GIoU Loss**: 회전 객체를 2D Gaussian으로 근사하여 거리를 최소화하는 손실 함수 도입
5. **NWD 기반 평가**: 주어진 데이터는 작은 객체 위주이므로, 이에 적합한 새로운 평가 방식 도입

- **자동라벨링 파이프라인 구축**

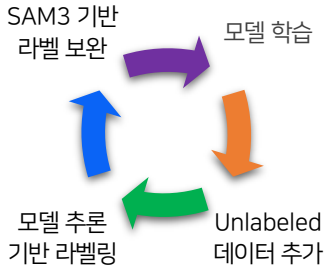

✓ 학습 모델과 SAM3를 통해 새로운 데이터를 **자동라벨링**하여 모델 성능을 반복적으로 개선하였습니다.

- **평가 결과**

✓ 정량평가

	Precision	Recall	mAP
Yolo	0.562	0.414	0.421
Ours	0.894	0.829	0.827

✓ 기존 Yolo 기반 사내 모델 대비 **mAP기준 96.43%** 성능 향상 달성

2023 대학생 창작 모빌리티 경진대회

ajou nice 팀

Overview

- 대회 개요
  - ✓ WeGo-ERP42 플랫폼에 **자율주행 시스템**을 탑재하여 주어진 미션을 해결하는 대회입니다.
  - ✓ 2023년 4월부터 10월까지 자율주행 실험도시인 K-city에서 실주행을 거치며 시스템 성능을 검증하고 개선했습니다.
- 기여 사항
  - ✓ 10인 1팀으로 구성된 팀에서 **부팀장** 및 **비전 팀장** 역할을 수행하며, 프로젝트의 전반적인 일정을 관리하고 팀원 간의 협업을 이끌었으며, 특히 비전 파트의 **신호등 및 표지판 인식**, **정지선 검출 알고리즘** 개발을 총괄했습니다.

Details

- 신호등 및 표지판 인식

[신호등 Class]

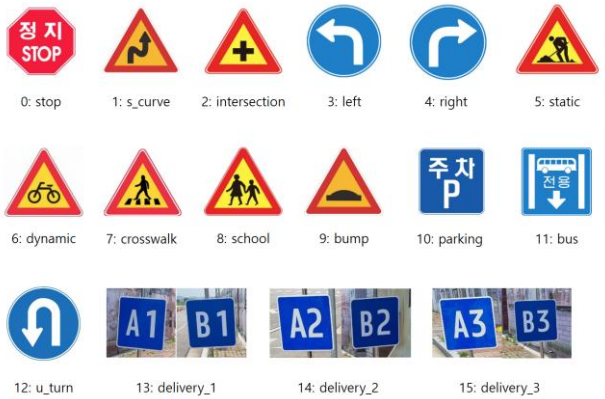

[표지판 Class]

[학습 결과]

- 정지선 검출

[Warped 이미지]

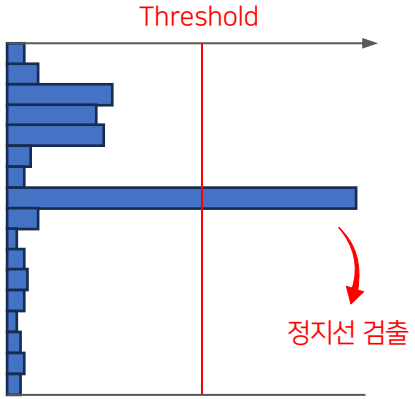

[히스토그램]

✓ 직접 수집한 신호등 및 표지판 데이터를 Roboflow Annotation 툴을 통해 라벨링한 후, YOLOv7 모델을 학습시켜 객체 탐지 모델을 개발했습니다. 또한 모델을 ROS 노드로 구성하여, 인식 결과를 실시간 토픽으로 발행하는 시스템을 구현했습니다.

✓ BEV/HSV 이미지 전처리 및 히스토그램/미분 필터 기반의 피크 분석을 통해 강인한 정지선 검출 알고리즘을 개발했습니다.

AI 융합 아이디어 경진대회 (AWS DeepRacer Championship)

강화학습 기반 AI 대회

Overview

- 대회 개요
  - ✓ **강화학습**을 통해 DeepRacer Agent를 훈련하여 가장 빠른 시간 내에 트랙 주행하는 대회였습니다.
  - ✓ **AWS 클라우드 기반 시뮬레이터**를 기반으로 강화학습을 통해 성능을 개선하여 최종 **1등상 (인천광역시장상)**을 수상했습니다.
- 기여 사항
  - ✓ **보상 함수(Reward Function)**와 **행동 공간(Action Space)**을 직접 설계 및 수정하며 Agent의 주행 성능을 개선했습니다.
  - ✓ Waypoint 기반 커스텀 함수를 통해 Agent 학습 **환경(Environment)**을 설계하며 성능을 최적화했습니다.

본선 대회에서 주행중인 사진

Details

- 보상 함수 (Reward Function) 설계

✓ Agent가 Waypoint를 가장 잘 따라갈 수 있도록 다음과 같이 보상 함수를 설계하였습니다.

[보상 함수 설계]

a. Agent를 기준으로 일정한 반지름의 원을 생성하여 Waypoint와 원의 교점을 구함

b. Agent 바퀴가 가리키는 방향이 Waypoint와 가까울수록 큰 보상을 줌

- 행동 공간 (Action Space) 설계

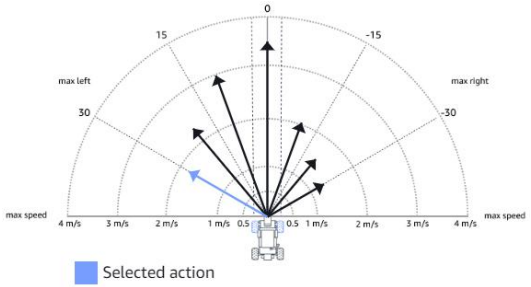

[행동 공간 설계]

✓ 총 7개의 Action Space를 설정하였습니다.

✓ 주행방향이 반시계방향이므로, 안쪽 방향인 왼쪽에 더 큰 가중치를 주도록 설계했습니다.

- 환경 (Environment) 설계

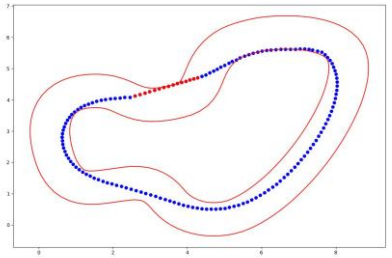

✓ Waypoint 기반 커스텀 함수를 통해 Agent의 학습 환경(Environment)을 생성했습니다.

a. 트랙의 중앙점들을 input으로 사용

b. i-1 점과 i+1 점의 평균으로 i 점을 구함

c. 위의 a, b과정을 반복 수행하여 최종 Waypoint 생성

RAG와 LangChain 기반 QA bot 프로젝트

AI Agents Using RAG and LangChain

Overview

- **프로젝트 개요**
  - ✓ Coursera의 **Fundamentals of AI Agents Using RAG and LangChain** 교육을 수료했습니다.
  - ✓ PDF 문서를 임베딩해 벡터 DB를 구축하고, 검색된 문서를 바탕으로 사용자의 질문에 답변하는 **QA Bot**을 구현했습니다.
- **학습 사항**
  - ✓ RAG와 LangChain의 핵심 개념부터 프롬프트 엔지니어링, FAISS 기반 벡터 검색까지 **AI Agent 설계에 필요한 기반 지식**을 학습했습니다
  - ✓ QA Bot을 직접 구현하며 문서 임베딩, 벡터 DB 연동, 텍스트 분할, Gradio UI 연동 등 **RAG 기반 Agent 구현 역량**을 길렀습니다.

Details

- **세부 모듈**

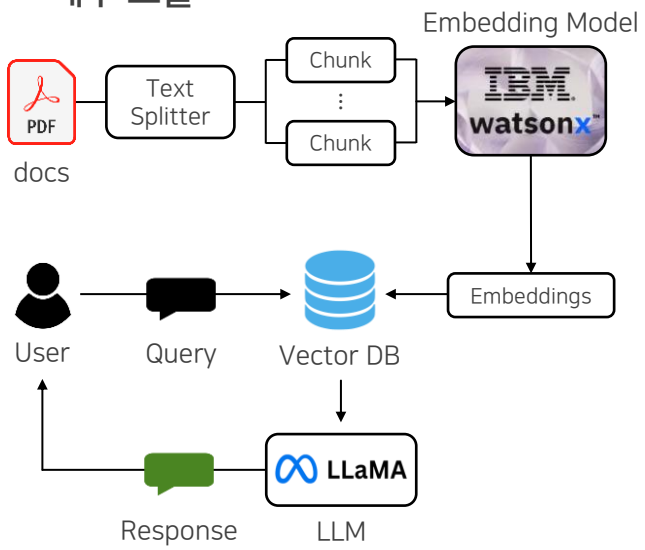

[QA bot 흐름도]

- **Text Splitter**
  - ✓ **LLM에게 충분한 정보 제공**을 위해 chunk_size=1000, **context 흐름 유지**를 위해 overlap=100으로 설정
- **Embedding Model**
  - ✓ 영어 문서에 특화된 IBM의 **Slate 125M English 모델** 사용
- **Vector DB**
  - ✓ 문서 임베딩을 효율적으로 저장하고 관리하기 위해 **Chroma DB** 기반 벡터 데이터베이스를 구축
- **Retriever**
  - ✓ 빠르고 효율적인 검색을 위해 Similarity Search 기반 Retriever를 구성
- **Web UI**
  - ✓ **Gradio**를 활용해 사용자가 직관적으로 상호작용할 수 있는 웹 인터페이스를 생성
- **최종 결과**

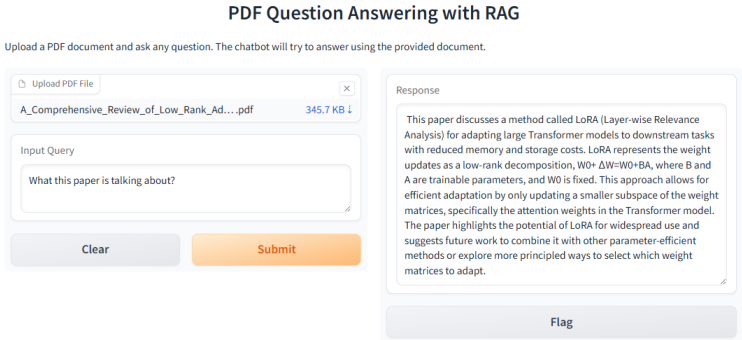

[QA bot 인터페이스]

- ✓ 웹 인터페이스에 논문을 업로드하여 실제 질의응답 테스트를 진행한 결과, QA Bot이 RAG 파이프라인을 통해 핵심 내용을 논리적으로 요약하여 답변을 생성하는 것을 확인했습니다.
- ✓ LLM-only와 RAG 파이프라인의 Ablation Study를 통해 **RAG 파이프라인의 우수성**을 검증했습니다.

2023 경기도 자율주행센터 데이터 활용 경진대회

3D 객체 인식 분야

Overview

- 프로젝트 개요
  - ✓ 경기도 자율주행센터의 빅데이터를 활용한 AI모델/데이터 분석 대회에 참가하여, **은상**을 수상했습니다.
  - ✓ 최종적으로 pointpillar 기반의 기존 방식보다 mAP를 **8.9%** 향상시켰습니다.
- 기여 사항
  - ✓ 3인 1팀으로 구성된 팀에서, 라이다 포인트 클라우드 및 JSON 형식의 정답 데이터를 좌표계 변환을 통해 KITTI 표준 형식으로 변환하는 **전처리 파이프라인**을 구축하는 역할을 수행했습니다.

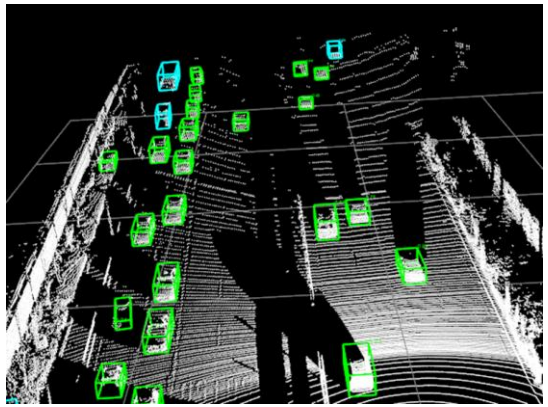

3D 객체 인식 결과

Details

- 모델 파이프라인

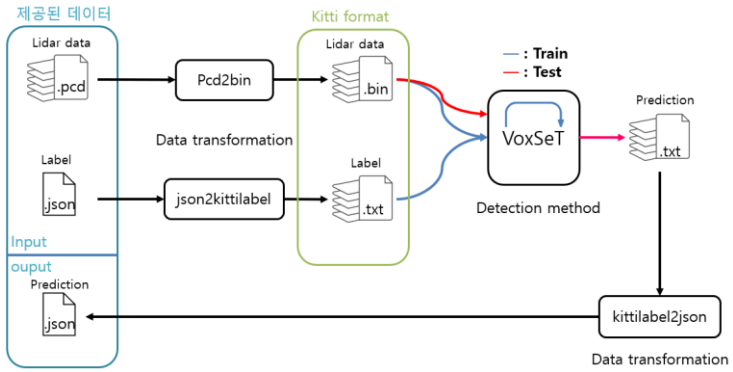

전체 프로세스 과정

1. 데이터 전처리
   - ✓ KITTI 형식에 맞게 라이다 포인트 클라우드 및 라벨을 변환합니다.
2. 모델 학습
   - ✓ 복셀 기반의 3D 객체 탐지를 수행하는 Transformer 모델인 VoxSeT을 학습합니다.
3. 학습 결과 평가
   - ✓ mAP를 통한 정량 평가 및 정성 평가를 진행합니다.

1. 포인트 클라우드 전처리

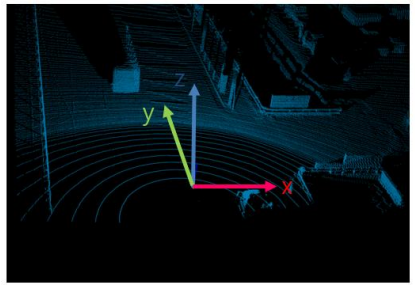

<Original coordinate>

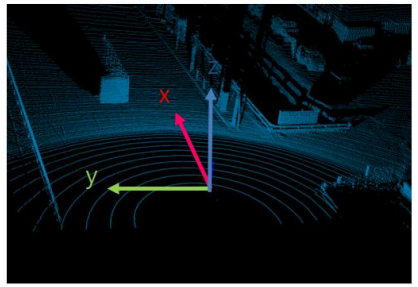

<Kitti lidar coordinate>

2. 라벨 전처리

- Rotation

$$\begin{bmatrix} X_c \\ Y_c \\ Z_c \end{bmatrix} = \begin{bmatrix} r_{11} & r_{12} & r_{13} & t_1 \\ r_{21} & r_{22} & r_{23} & t_2 \\ r_{31} & r_{32} & r_{33} & t_3 \end{bmatrix} \begin{bmatrix} 0 & 1 & 0 & 0 \\ -1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix}$$

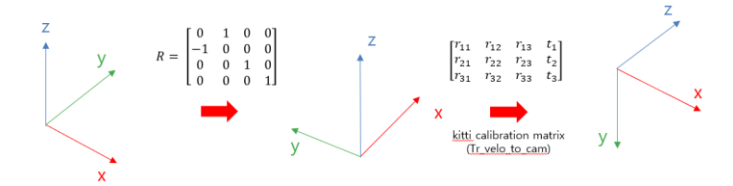

<World coordinate> <lidar coordinate> <Camera coordinate>

- Translation

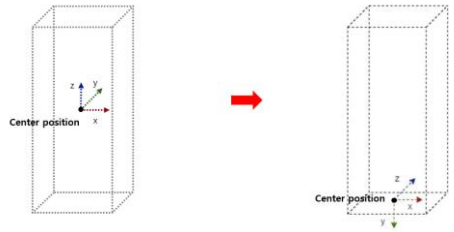

<Center position of original label> <Center position of Kitti label>

번호판 비식별화 프로젝트

융합캡스톤디자인1

Overview

- 프로젝트 개요
  - ✓ 융합캡스톤디자인1 과목에서 번호판 비식별화 프로젝트를 진행하고, 전자공학과 산학박람회에서 **장려상**을 수상했습니다.
  - ✓ **딥러닝 기반의 파이프라인 설계 역량** 및 **문제 해결 역량**을 기를 수 있었습니다.
- 기여 사항
  - ✓ 3인 1팀으로 구성된 팀에서, **번호판 검출** 및 **유형 분류 모듈**을 설계 및 학습하고 성능 비교를 수행했습니다.
  - ✓ 번호판 비식별화 모듈 개발을 위해 **생성형 AI (Pix2Pix)**를 통한 방법을 탐색했습니다.

입력 출력

번호판 비식별화 결과

Details

1. 번호판 검출

입력 Bounding box 4 Coordinates

✓ Task의 간소화를 위해 **2-Stage 파이프라인**으로 번호판을 검출했습니다.

1) 번호판 위치 탐색: Yolov5를 통해 번호판의 대략적인 위치를 탐색합니다.

2) 번호판 꼭짓점 추출: Resnet34를 통해 번호판의 정확한 4 꼭짓점 좌표를 추출합니다.

2. 번호판 유형 분류

번호판 종류

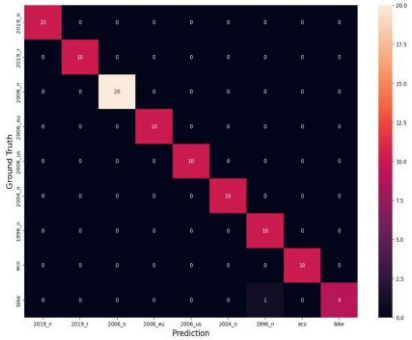

번호판 유형 분류 결과 (Confusion Matrix)

✓ 이후 유형에 따른 가짜 번호판 생성을 위해, Classification 모델(Resnet18+fc layer)을 사용하여 번호판 이미지를 입력으로 받고 9개의 번호판 유형을 예측합니다.

3. 번호판 비식별화

1) 가짜 번호판 생성

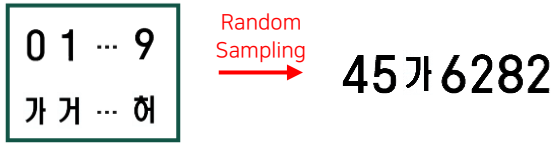

✓ Random Sampling을 통해 가짜 번호판을 생성합니다.

2) Pix2Pix를 통한 번호판 비식별화

✓ **생성형 모델 (Pix2Pix)**를 통해 가짜 번호판을 입력으로 받고 비식별화된 이미지를 생성합니다.

MTMCT (Multi-Target Multi-Camera Tracking) 프로젝트

융합캡스톤디자인2

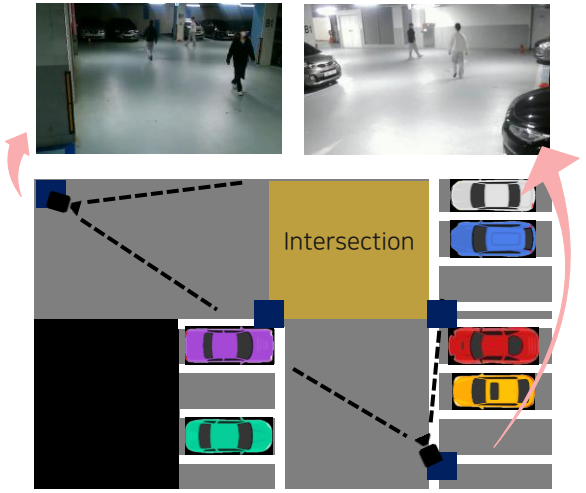

Overview

- **프로젝트 개요**
  - ✓ 융합캡스톤디자인2 과목에서 다중 카메라를 통해 다중 객체를 추적하는 프로젝트를 진행했습니다.
  - ✓ 2개의 카메라를 통해 강의실과 주차장에서 데이터를 직접 수집한 후, 다수의 객체를 일관되게 추적하는 프로젝트입니다.
- **기여 사항**
  - ✓ 3인 1팀으로 구성된 팀에서, 데이터셋을 **직접 수집하고 전처리** 했으며, 객체 인식을 위한 YOLO, 특징 추출을 위한 OSNet을 통해 객체 추적 파이프라인을 구현했습니다.
  - ✓ MOTA, IDF1 평가 지표를 통해 모델의 성능을 평가했습니다.

Details

- **모델 파이프라인**

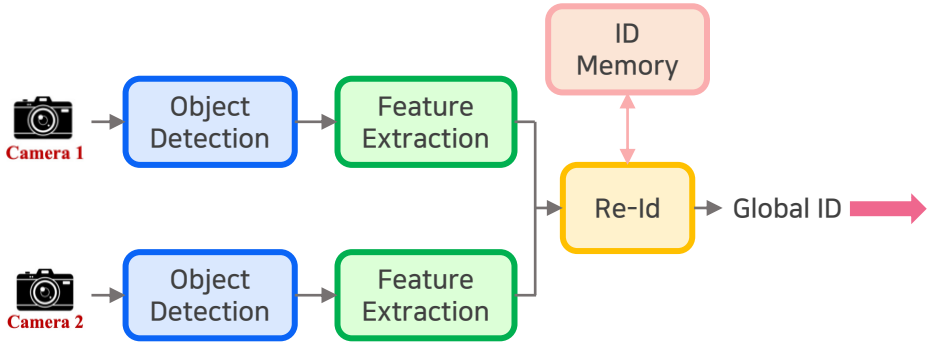

MTMCT 파이프라인

객체 추적 결과

1. 객체 탐지 (Object Detection)
   - ✓ YOLOv7 모델을 통해 객체를 탐지합니다.
2. 특징 추출 (Feature Extraction)
   - ✓ Re-ID에 특화된 OSNet을 통해 객체 특징을 추출합니다.
3. 재식별 (Re-Identification)
   - ✓ Cosine 유사도를 통해 헝가리안 알고리즘으로 ID를 할당합니다.

- **평가 결과**

	MOTA	IDF1
Room	0.917	0.787
Parking lot	0.923	0.753

정량 평가 결과

- ✓ 평가 지표
  - MOTA

$$MOTA = 1 - \frac{\sum_t (m_t + fp_t + mm_t)}{\sum_t g_t}$$

  - IDF1

$$IDF1 = \frac{\sum_t 2 \cdot T_{p_t}}{\sum_t (g_t + p_t)}$$

시연 영상